





요약

- ❖ 분류 기법 소개
 - 분류 기법의 정의
 - 분류 기법의 특징
 - 대표 분류 기법 소개 (KNN, Decision tree)
- ❖ KNN(K-Nearest Neighbor) 실습 KNN 기반 KDD 데이터 분류
 - 데이터 로드 및 전처리
 - sklearn 라이브러리를 활용한 학습
 - 결과 확인
- ❖ 의사결정트리(Decision Tree) 실습 결정트리 기반 KDD 데이터 분류
 - 데이터 로드 및 전처리
 - Sklearn 라이브러리를 활용한 학습
 - 결과 확인
- ❖ MNIST 데이터 분류 및 성능 측정
 - MNIST 데이터 분류
 - 성능 측정 방법

요약

❖ 클러스터링 분석

- 클러스터링 분석이란?
- 데이터간 유사도
- 주요 클러스터링 기법
- 클러스터간 거리 측정

Dimensionality reduction

Principal Component Analysis(PCA)

❖ K-means Algorithm

- 알고리즘 설명
- Scikit-learn을 활용한 실습

❖ DBSCAN Algorithm

- 알고리즘 설명
- Scikit-learn을 활용한 실습
- 과제 소개

분류









분류 (Classification)

- ❖ 머신러닝 기법 중 하나로, 기존의 관측치(label)가 있는 training data를 기반으로 학습하는 방법
 - 사전에 Categorical 데이터 및 데이터의 label을 요구
 - 지도학습으로 기존의 학습을 통하여, 새롭게 관측된 데이터의 category를 예측 가능




그림 3-1 MNIST 데이터셋에서 추출한 숫자 이미지

KDD Cup 1999 Data

Abstract

This is the data set used for The Third International Knowl to build a network intrusion detector, a predictive model a variety of intrusions simulated in a military network environment.

Information files:

• task description. This is the original task decription g

Data files:

- kddcup.names A list of features.
- kddcup.data.gz The full data set (18M; 743M Uncom
- kddcup.data 10 percent.gz A 10% subset. (2.1M; 75N
- kddcup.newtestdata 10 percent unlabeled.gz (1.4M;
- kddcup.testdata.unlabeled.gz (11.2M; 430M Uncomp
- kddcup.testdata.unlabeled 10 percent.gz (1.4M;45M
- corrected.gz Test data with corrected labels.
- <u>training attack types</u> A list of intrusion types.
- typo-correction.txt A brief note on a typo in the data

그림 3-2 KDD Cup Data 페이지

KNN (K-Nearest Neighbor)

- ❖ 분류 기법 중 하나로, 데이터를 거리가 가장 가까운 k개의 데이터를 참고하여 데이터를 분류하는 방법
 - 데이터 간의 거리를 측정하기 위해, Euclidian Distance를 사용
 - K값에 따른 성능 차이 존재 (일반적으로 총 데이터의 제곱근 값을 사용)




그림 1-15. 사례 기반 학습

❖ Dataset load를 위한 import 및 column 이름 설정

- ❖ 10percent dataset load 및 확인
 - 학습 속도를 위해 10percent dataset을 사용
 - names 옵션에 방금 입력한 col_names를 입력
 - head 함수를 통해 데이터셋 샘플 조회

```
In [2]: kdd_data_10percent = pandas.read_csv("./kddcup.data_10_percent_corrected", names =
    col_names)
    kdd_data_10percent.head()
```

Out [2] :	du	ration	protocol_type	service	flag	src_bytes	dst_bytes	land	wrong_fragment	urgent	hot	 dst_host_srv_coun
	0	0	tcp	http	SF	181	5450	0	0	0	0	 ,
	1	0	tcp	http	SF	239	486	0	0	0	0	 19
	2	0	tcp	http	SF	235	1337	0	0	0	0	 29
	3	0	tcp	http	SF	219	1337	0	0	0	0	 39
	4	0	tcp	http	SF	217	2032	0	0	0	0	 49

❖ Class별 데이터셋 개수 조회

■ 딕셔너리 및 value_counts 함수를 활용하여 클래스 별 데이터 개수 조회

In [3]: kdd_data_10percent['label'].value_counts()

Out [3] :	smurf.	280790			
	neptune.	107201			
	normal.	97278			
	back.	2203			
	satan.	1589			
	ipsweep.	1247			
	portsweep.	1040			
	warezclient.	1020			
	teardrop.	979			
	pod.	264			
	nmap.	231			
	guess_passwd.	53			
	buffer_overflow.	30			
	land.	21			
	warezmaster.	20			
	imap.	12			
	rootkit.	10			
	loadmodule.	9			
	ftp_write.	8			
	multihop.	7			
	phf.	4			
	perl.	3			
	spy.	2			

❖ Categorical data 변환

학습에 사용할 categorical data를 조회

In [4]: print(kdd data 10percent.dtypes) int64 Out [4]: duration protocol_type object service object flag object src_bytes int64 dst_bytes int64 int64 land float64 dst_host_srv_serror_rate dst host rerror rate float64 dst_host_srv_rerror_rate float64 label object

❖ Categorical data 변환

■ pandas의 factorize 함수를 사용하여, categorical data를 정수화

```
In [5]:
        kdd_data_10percent['protocol_type'], protocols=
        pandas.factorize(kdd_data_10percent['protocol_type'])
        kdd_data_10percent['service'], services =
        pandas.factorize(kdd_data_10percent['service'])
        kdd_data_10percent['flag'], flags = pandas.factorize(kdd_data_10percent['flag'])
        kdd data 10percent['label'], attacks = pandas.factorize(kdd data 10percent['label'])
        print(kdd data 10percent.dtypes)
Out [5]: duration
                                  int64
                                   int64
          protocol type
          service
                                 int64
          flag
                                int64
          src bytes
                                  int64
          dst_bytes
                                  int64
          land
                                 int64
                                    float64
          dst host srv serror rate
          dst host rerror rate
                                   float64
                                    float64
          dst host srv rerror rate
          label
                                int64
```

❖ Training set Test set 분류

train_test_split 함수 기반의 train set / test set 분류

```
In [6]: from sklearn.model_selection import train_test_split

# 기존에 정의했던 col_names를 사용하여 label과 features를 분리
X = kdd_data_10percent[col_names]:len(col_names)-1]]
Y = kdd_data_10percent['label'].copy()

# Train set과 Test set을 8:2 비율로 분리
X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size=0.2, random_state=123)

In [7]: # Train set label 조회
Y_train.value_counts()

In [8]: # Test set label 조회
Y_test.value_counts()
```

❖ 데이터 셋 축소

■ 노트북 사용 시, 학습에 상당한 시간이 걸리므로 수업에서는 데이터 셋 10만개만을 사용

```
In [9]: kdd_data_10percent = kdd_data_10percent[:100000]

In # Train set label 조회
[10]: Y_train.value_counts()

In # Test set label 조회
[11]: Y_test.value_counts()
```

❖ KNN 분류 모델 학습

■ n = 5로 학습


❖ KNN 분류 모델 학습

■ n = 5로 학습 및 결과 확인

```
from sklearn.neighbors import KNeighborsClassifier
In
[13]:
        clf = KNeighborsClassifier(n_neighbors = 5)
        t0 = time()
        clf.fit(X_train, Y_train)
        tt = time() - t0
        print ("Classifier trained in {} seconds.".format(round(tt, 3)))
         Classifier trained in 1.763 seconds.
Out
[13]:
        print ("Training Score:", clf.score(X_train, Y_train))
In
[14]:
        print ("Test_Score: ", clf.score(X_test, Y_test))
Out
          Training Score: 0.9980125
          Test Score: 0.9969
[14]:
```

의사결정트리 (Decision tree)

- ❖ Root 노드부터 시작하여, attributes에 따라 true, false를 나누고 데이터를 구분하는 학습 기법
 - 데이터를 가장 잘 구분할 수 있는 질문을 기준으로 노드를 나눈 뒤, 이를 recursive하게 반복



의사결정트리 기반 KDD 데이터 분류

- ❖ sklearn의 DecisionTreeClassifier 함수를 사용
 - 기존 KNN 실습에 이어서 데이터 셋을 사용한다

Out Training Score: 1.0 [15]: Test_Score: 0.999

❖ MNIST 데이터 셋

■ 고등학생과 미국 인구 조사국 직원들이 작성한 7,000 개의 작은 숫자 이미지



그림 3-1 MNIST 데이터셋에서 추출한 숫자 이미지

❖ MNIST 데이터 셋

import numpy as np

In [1]:

■ 사이킷런의 헬퍼 함수를 이용한 데이터셋 다운로드

❖ MNIST 데이터 셋

- 딕셔너리 구조
 - · 데이터 셋을 설명하는 DESCR
 - 셈플이 하나의 행, 특성이 하나의 열로 구성된 배열을 가진 data 키
 - 레이블 배열을 담고 있는 target 키

In [2]: X, y = mnist["data"], mnist["target"]
X.shape

Out [2]: (70000, 784)

In [3]: y.shape

Out [3]: (70000,)

❖ MNIST 데이터 셋

- 샘플 한 개를 이미지화
 - · 샘플의 특성 벡터를 추출해서 28x28배열로 크기를 바꾸고 맷플롯립의 imshow() 함수를 사용

```
In [4]: %matplotlib inline
    import matplotlib.pyplot as plt
    X = np.array(X)
    y = np.array(y)
    some_digit = X[35]
    some_digit_image = some_digit.reshape(28, 28)
    plt.imshow(some_digit_image, cmap = matplotlib.cm.binary, interpolation="nearest")
    plt.axis("off")
    plt.show()
```



• 실제 레이블 확인

In [5]: y[36000]

Out [5]: 5.0

❖ 테스트 세트 생성

- MNIST 테이터 세트는 이미 훈련 세트와 테스트 세트로 나누어 놓음
 - · 훈련 세트: 앞쪽 60.000개, 테스트 세트: 뒤쪽 10.000개
 - 훈련 세트를 섞어서 모든 교차 검증 폴드가 비슷해지도록 만들자.
 - 하나의 폴드라도 특정 숫자가 누락되면 안 됨
 - 훈련 샘플의 순서에 민감한 학습 알고리즘도 있으므로 비슷한 샘플이 연이어 나타나면 안 됨

In [6]: # 훈련 데이터와 테스트 데이터를 나누기 위한 코드

 X_{train} , X_{test} , y_{train} , y_{test} = X[:60000], X[60000:], y[:60000], y[:60000:]

#데이터 셔플링

import numpy as np

shuffle_index = np.random.permutation(60000)
X_train, y_train = X_train[shuffle_index], y_train[shuffle_index]

이진 분류기 훈련

❖ 숫자 5를 식별하는 감지기

- '5' 와 '~5' 두 개의 클래스를 구분할 수 있는 이진 분류기 (binary classifier)
- 타깃 벡터 생성

In [7]: #5는 True고, 다른 숫자는 모두 False y_train_5 = (y_train == '5') y_test_5 = (y_test == '5')

- 분류 모델을 선택해서 훈련시킴
 - SGDClassifier 클래스를 사용해 확률적 경사 하강법(Stochastic Gradient Decent: SGD) 분류기 적용
 - 훈련할 때 무작위성을 사용함
 - 결과를 재현하고 싶으면 random_state 매개변수를 사용함

In [8]: #SGDClassifier 모델 생성 및 훈련 코드

from sklearn.linear_model import SGDClassifier

sgd_clf = SGDClassifier(random_state=42)
sgd_clf.fit(X_train, y_train_5)

- 숫자 5의 이미지를 감지

In [9]: sgd_clf.predict([some_digit])

Out [9]: array([True])

성능 측정

❖ cross_val_score() 함수로 폴드가 3개인 K(=3)-fold cross validation을 사용해 SGDClassifier 모델을 평가

```
In [11]: from sklearn.model_selection import cross_val_score 
cross_val_score(sgd_clf, X_train, y_train_5, cv=3, scoring="accuracy")
```

Out [11]: array([0.9619, 0.96645, 0.96645])

❖ 모든 이미지를 '5', '~5'클래스로 분류하는 더미 분류기

```
In [12]: from sklearn.base import BaseEstimator
    class Never5Classifier(BaseEstimator):
        def fit(self, X, y=None):
            pass
        def predict(self, X):
            return np.zeros((len(X), 1), dtype=bool)

        never_5_clf = Never5Classifier()
        cross_val_score(never_5_clf, X_train, y_train_5, cv=3, scoring="accuracy")
```

Out [12]: array([0.90975 , 0.90745, 0.91175])



오차 행렬 (confusion matrix)

- ❖ 오차 행렬을 만들려면 실제 타깃과 비교할 수 있도록 먼저 예측 값을 생성한다.
 - cross_val_predice() 메서드를 사용
 - K-fold 교차 검증을 수행하지만 평가 점수를 반환하지 않고 각 테스트 폴드에서 얻은 예측을 반환함

In [13]: # 예측값 생성 코드

from sklearn.model_selection import cross_val_predict

y_train_pred = cross_val_predict(sgd_clf, X_train, y_train_5, cv=3)

오차 행렬 생성 코드

from sklearn.metrics import confusion_matrix

confusion_matrix(y_train_5, y_train_pred)


Out [13]: array([[53918, 661], [1447, 3974]], dtype=int64)

• 완벽한 분류기

In [14]: y_train_perfect_predictions = y_train_5

confusion_matrix(y_train_5, y_train_perfect_predictions)

Out [14]: array([[54579, 0], [0, 5421]], dtype=int64)



<u>그림 3-2 오차행렬</u>

오차 행렬 (confusion matrix)

- ❖ 정밀도 (precision)
 - $\operatorname{Agg} = \frac{TP}{TP + FP}$, TP: 진짜 양성의 수, FP: 거짓 양성의 수
 - 분류기가 정확하게 감지한 양성 예측의 정확도

In [15]: from sklearn.metrics import precision_score, recall_score

정밀도 계산 함수 precision_score(y_train_5, y_train_pred)

Out [15]: 0.8573894282632146

- ❖ 재현율 (recall 혹은 sensitivity)
 - 재현율= $\frac{TP}{TP+FN}$, FN: 가짜 음성의 수
 - 분류기가 정확하게 감지한 양성 샘플의 비율

In [16]: # 재현율 계산 함수 recall_score(y_train_5, y_train_pred)

Out [16]: 0.7330750783988194



오차 행렬 (confusion matrix)

❖ F-1 Score (점수)

- 두 분류기를 비교할 때 사용
- 정밀도와 재현율의 조화 평균

$$F_1 = \frac{2}{\frac{1}{\text{정밀도} + \frac{1}{\text{재현율}}}} = 2 \times \frac{\text{정밀도} \times \text{재현율}}{\text{정밀도} + \text{재현율}} = \frac{TP}{TP + \frac{FN + FP}{2}}$$

In [17]: from sklearn.metrics import f1_score f1_score(y_train_5, y_train_pred)

Out [17]: 0.7903739061256961

❖ 정밀도/재현율 트레이드오프




그림 3-3 결정 임곗값과 정밀도/재현율 트레이드오프

정밀도/재현율 트레이드오프

- ❖ 임계값을 직접 지정할 수는 없지만 예측에 사용한 각 샘플의 점수는 확인 가능
 - predict() 메서드 대신 decision_function() 메서드를 호출

```
In [18]: y scores = sqd clf.decision function([some digit])
         y_scores
Out [18]: array([19516.2894736])
In [19]: threshold = 0
         y_some_digit_pred = (y_scores > threshold)
         y some digit pred
Out [19]: array([ True])
In [20]: threshold = 200000
         y_some_digit_pred = (y_scores > threshold)
         y_some_digit_pred
Out [20] : array([ False])
```

정밀도/재현율 트레이드오프

- ❖ 적절한 임계 값을 정하는 방법
 - cross_val_predict() 메소드르 사용해 훈련 세트에 있는 모든 샘플의 점수를 계산
 - precision_recall_curve() 메소드를 사용하여 가능한 모든 임계 값에 대해 정밀도와 재현률을 계산
 - 맷플롯립을 이용해 임계 값의 함수로 정밀도와 재현율을 그림

```
In [21]: y scores = cross val predict(sqd clf, X train, y train 5, cv=3, method="decision function")
          from sklearn.metrics import precision_recall_curve
          # 가능한 모든 임곗값에 대해 정밀도와 재현율을 계산하는 코드
          precisions, recalls, thresholds = precision recall curve(y train 5, y scores)
          # 정밀도와 재현율 그래프 생성 함수
          def plot_precision_recall_vs_threshold(precisions, recalls, thresholds):
             plt.plot(thresholds, precisions[:-1], "b--", label="Precision")
             plt.plot(thresholds, recalls[:-1], "g-", label="Recall")
             plt.xlabel("Threshold")
                                                                                   --- Precision
                                                                                      Recall
             plt.legend(loc="upper left")
                                                                               0.8
             plt.ylim([0, 1])
                                                                               0.6
          plot precision recall vs threshold(precisions, recalls, thresholds)
          plt.show()
                                                                               0.4
                                                                               0.2
                                                                                 -2000000-1500000-1000000 -500000
                                                                                                              500000 1000000
```

정밀도/재현율 트레이드오프

❖ 적절한 임계 값을 정하는 방법

재현율에 대한 정밀도 곡선을 그림

In [22]: y_train_pred_90 = (y_scores > 70000) precision_score(y_train_5, y_train_pred_90) recall score(y train 5, y train pred 90) 0.8 #정밀도와 재현율 def plot_precision_vs_recall(precisions, recalls): plt.plot(recalls, precisions, "b-", linewidth=2) Precision 9.0 plt.xlabel("Recall", fontsize=16) plt.ylabel("Precision", fontsize=16) plt.axis([0, 1, 0, 1]) plt.figure(figsize=(8, 6)) plot precision vs recall(precisions, recalls) 0.2 plt.show() 0.0 예제

정밀도 90% 달성이 목표

In [23]: #훈련 세트에 대한 예측 만들기 y train pred 90 = (y scores > 70000)

> # 임계값이 70,000 이상에서의 정밀도 코드 precision score(y train 5, y train pred 90)

재현율은?


Recall

0.8

0.2

Out [23]: 0.9223995597138139

- **♦** What is Cluster Analysis?
 - 주어진 데이터의 특성을 고려하여 데이터 군집을 형성하여 데이터를 분석하는 기법
 - 각 클러스터는 비슷한 특성을 가진 데이터를 포함함



◆ 데이터간 유사도 정의

- 데이터 간 거리(Distance metrics)가 데이터 간 유사도를 나타내는 척도로 널리 사용됨
Minkowski distance

$$d(i,j) = \sqrt[p]{\sum_{k=1}^{d} (x_{ik} - x_{jk})^p}$$

각각의 오브젝트 i, j는 d 차원으로 구성됨 p = 1일 때, d(i, j)는 Manhattan distance이며. p = 2일 때, d(i, j)는 Euclidean distance.

Cosine distance

$$d(i,j) = 1 - cosine \ similarity(i,j) = 1 - \frac{\mathbf{i} \cdot \mathbf{j}}{\|\mathbf{i}\| \|\mathbf{j}\|}$$

- **♦** How to Define Similarity?
 - 오브젝트가 items로 구성된 경우(ex. 카테고리)

Jaccard distance

$$d(i,j) = \frac{|A \cap B|}{|A \cup B|}$$

- 오브젝트가 수치 데이터와 카테고리 데이터를 모두 포함하는 경우 Weighted distance

$$d(i,j) = \frac{\sum_{k=1}^{d} w_k d_{i,j}^{(f)}}{\sum_{k=1}^{d} w_k}$$

f 는 Mincowski, Cosine, Jaccard, 등의 distance metric

♦ Major Clustering Approaches

- Partitioning approach

특정 기준을 활용하여 데이터 파티션을 구성

Algorithms: k-means, k-medoids, minibatch k-means

- Hierarchical approach


특정 기준을 활용하여 데이터를 계층적으로 구성


Algorithms: Agglomerative, BIRCH


Density-based Approach

밀도 함수를 활용하여 클러스터 형성

Algorithms: DBSCAN, OPTICS







- **♦** How to measure the distance between cluster?
 - Single link

두 클러스터의 오브젝트 간 거리 중 최소 거리

 $\min\{d(a,b)|a\in A,b\in B\}$

Complete link

두 클러스터의 오브젝트 간 거리 중 최대 거리

 $\max\{d(a,b)|a\in A,b\in B\}$

Average

두 클러스터의 모든 오브젝트 간 거리의 평균

- Centroid

두 클러스터의 중심점 간 거리

$$\left(\sum_{a \in A} \sum_{b \in B} d(a, b)\right) / |A| \cdot |B|$$

$$d(A,B) = d(c_A,c_B)$$

- Medoid


두 클러스터의 Medoid 간 거리

$$d(A,B) = d(m_A, m_B)$$

• Medoid: 클러스터 중심점에 가장 가까운 오브젝트

Dimensionality Reduction

- **♦** Principal Component Analysis(PCA)
 - 고차원 데이터의 정보 손실을 최소화 하면서 저차원 데이터로 변환하는 기법
 - covariance matrix 의 eigen value 와 vector를 계산하는 방식으로 계산됨



Dimensionality Reduction

♦ How to Calculate PCA

- Step 1. Standardization

```
In [1]: import numpy as np
In [2]: d = np.array([[170, 70], [150, 45], [160, 55], [180, 60], [170, 80]])
          d
Out [2] : array([[170, 70],
                 [150, 45],
                 [160, 55],
                 [180, 60],
                 [170, 80]])
In [3]: z = d - np.mean(d, axis=0)
          Z
Out [3] : array([[ 4., 8.],
                 [-16., -17.],
                 [-6., -7.],
                 [ 14., -2.],
                 [ 4., 18.]])
```

Dimensionality Reduction

♦ How to Calculate PCA

- Step 2. Calculate covariance vector

- Step 3. Calculate SVD

Dimensionality Reduction

♦ How to Calculate PCA

- Using scikit-learn

```
In [1] : from sklearn.decomposition import PCA
In [2]: d = np.array([[170, 70], [150, 45], [160, 55], [180, 60], [170, 80]])
          d
Out [2] : array([[170, 70],
                 [150, 45],
                 [160, 55],
                 [180, 60],
                 [170, 80]])
In [3] : d_pca = PCA(n_components=2).fit_transform(d)
          d_pca
Out [3]: array([[ -8.78288493, -1.69142909],
                 [ 23.22578413, -2.35859097],
                 [ 9.2057422 , -0.50429214],
                 [-6.9285861, 12.32861285],
                 [-16.72005531, -7.77430064]])
```

- **♦** Before We Start...
 - 네트워크 보안분야(IDS)에서 널리 사용되는 KDD99 셋을 사용
 - Download link

http://kdd.ics.uci.edu/databases/kddcup99/kddcup99.html

- 약 50만개의 레코드를 보유한 10% 데이터 사용

KDD Cup 1999 Data

Abstract

This is the data set used for The Third International Knowledge Discovery and Data Mining Tools Competition, which was held in conjunction with KDD-99 The Fifth International Conference on Knowledge Discovery and Data Mining. The competition task was to build a network intrusion detector, a predictive model capable of distinguishing between "bad" connections, called intrusions or attacks, and "good" normal connections. This database contains a standard set of data to be audited, which includes a wide variety of intrusions simulated in a military network environment.

Information files:

• task description. This is the original task decription given to competition participants.

Data files:

- kddcup.names A list of features.
- kddcup.data.gz The full data set (18M; 743M Uncompressed)
- kddcup.data 10 percent.gz A 10% subset. (2.1M; 75M Uncompressed)
 This one!!
- kddcup.newtestdata 10 percent unlabeled.gz (1.4M; 45M Uncompressed)
- kddcup.testdata.unlabeled.gz (11.2M; 430M Uncompressed)
- kddcup.testdata.unlabeled 10 percent.gz (1.4M;45M Uncompressed)
- · corrected.gz Test data with corrected labels.
- training attack types A list of intrusion types.
- typo-correction.txt A brief note on a typo in the data set that has been corrected (6/26/07)


♦ K-Means Algorithm


- Partitioning 기반의 Clustering 알고리즘
- 총 3단계로 구성되며 주로 마지막 두 단계가 반복 수행됨
- Algorithm
 - Setp1. Centroids 초기화


Setp2. 오브젝트들을 가장 가까운 Centroid의 클러스터로 지정


Setp3. 각 클러스터의 새로운 Centroid를 계산


Setp4. Centroid가 수렴할 때까지 반복











♦ K-means Algorithm with KDD-99 Dataset

- Step 1. Import all package

```
In [1]: import csv
    import numpy as np
    import pandas as pd
    import matplotlib.pyplot as plt

    from sklearn import metrics
    from sklearn.cluster import KMeans
    from sklearn.decomposition import PCA
    from sklearn.preprocessing import MinMaxScaler
```

- Step 2. Load KDD-99 Dataset

♦ K-means Algorithm with KDD-99 Dataset

```
In [3] : with open('./kddcup.data_10_percent_corrected', 'r') as file:
             data = pd.read csv(file, names=col names)
In [4]: data['label'].value counts()
Out [4]: smurf. 280790
          neptune. 107201
          normal, 97278
          back. 2203
          satan. 1589
          ipsweep. 1247
          portsweep. 1040
          warezclient. 1020
          teardrop. 979
          pod. 264
          nmap. 231
          guess_passwd. 53
          buffer_overflow. 30
          land. 21
          warezmaster. 20
          Name: label, dtype: int64
```

♦ K-means Algorithm with KDD-99 Dataset

- Step 3. Extract data by several per label

```
In [5] : unique_labels = data['label'].unique()
            unique labels
Out [5]: array(['normal.', 'buffer overflow.', 'loadmodule.', 'perl.', 'neptune.', 'smurf.',
                    'guess_passwd.', 'pod.', 'teardrop.', 'portsweep.', 'ipsweep.', 'land.',
                    'ftp_write.', 'back.', 'imap.', 'satan.', 'phf.', 'nmap.', 'multihop.',
                    'warezmaster.', 'warezclient.', 'spy.', 'rootkit.'], dtype=object)
In [6] : selected data = pd.DataFrame()
            for label in unique labels:
                 selected data = pd.concat([selected data, data.loc[data['label'] == label][:200]])
            selected data
Out [6]:
                  duration protocol_type service flag src_bytes dst_bytes land wrong_fragment urgent hot ... dst_host_srv_count dst_host_same_srv_rate dst_l
                                                                           0 0 ...
                0
                       0
                                    http
                                        SF
                                               181
                                                     5450
                                                                                                           1.00
                                                                              0 ...
                               tcp
                                    http
                                        SF
                                               239
                                                     486
                                                           0
                                                                                            19
                                                                                                           1.00
                                                                           0 0 ...
                                    http SF
                                               235
                                                     1337
                                                                                                           1.00
                       0
                                       SF
                                                                           0 0 ...
                                                                                                           1.00
                                    http
                                               219
                                                     1337
                                                                                            39
                               tcp
                                    http SF
                                               217
                                                     2032
                                                                           0 0 ...
                                                                                                           1.00
```

♦ K-means Algorithm with KDD-99 Dataset

- Step 3. Extract data by several per label

```
In [7] : selected_data['label'].value_counts()
Out [7]: satan. 200
          ipsweep. 200
          warezclient. 200
          teardrop. 200
          normal. 200
          portsweep. 200
          nmap. 200
          back. 200
          smurf. 200
          neptune. 200
          pod. 200
          guess_passwd. 53
          buffer overflow. 30
          land. 21
          warezmaster. 20
          imap. 12
          rootkit. 10
          loadmodule. 9
          Name: label, dtype: int64
```

♦ K-means Algorithm with KDD-99 Dataset

- Step 4. Separate data and label

```
In [8]: labels = selected_data['label'].to_numpy()
labels
Out [8]: array(['normal.', 'normal.', ..., 'rootkit.', 'rootkit.'], dtype=object)
In [9]: data = selected_data.drop('label', axis=1)
data
```

Out [9]:

	duration	protocol_type	service	flag	src_bytes	dst_bytes	land	wrong_fragment	urgent	hot	 dst_host_count	dst_host_srv_count	dst_host_sam
0	0	tcp	http	SF	181	5450	0	0	0	0	 9	9))
1	0	tcp	http	SF	239	486	0	0	0	0	 19	19	
2	0	tcp	http	SF	235	1337	0	0	0	0	 29	29	
3	0	tcp	http	SF	219	1337	0	0	0	0	 39	39	
4	0	tcp	http	SF	217	2032	0	0	0	0	 49	49	
142477	0	tcp	ftp_data	SF	0	5636	0	0	0	0	 1	41	
148154	61	tcp	telnet	SF	294	3929	0	0	0	0	 255	4	
397011	0	udp	other	SF	32	0	0	0	0	0	 255	1	

♦ K-means Algorithm with KDD-99 Dataset

- Step 5. Convert nominal data to numeric data

```
In [10]:
                                                                         data['protocol_type'], _ = data['protocol_type'].factorize()
                                                                          data['service'], _ = data['service'].factorize()
                                                                          data['flag'], _ = data['flag'].factorize()
                                                                          data
Out [10]:
                                                                                                      duration protocol_type service flag src_bytes dst_bytes land wrong_fragment urgent hot ... dst_host_count dst_host_srv_count ds
                                                                                           0
                                                                                                                             0
                                                                                                                                                                                                                                                                                                                          0
                                                                                                                                                                                                                                                                                                                                                                                                                0 0 ...
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                   9
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                       9
                                                                                                                                                                                                                                                            181
                                                                                                                                                                                                                                                                                            5450
                                                                                           1
                                                                                                                            0
                                                                                                                                                                                                                                                           239
                                                                                                                                                                                                                                                                                                                          0
                                                                                                                                                                                                                                                                                                                                                                                                                0 0 ...
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                19
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                    19
                                                                                                                                                                                                                                                                                               486
                                                                                                                                                                                                                                                           235
                                                                                                                                                                                                                                                                                                                                                                                                                                0 ...
                                                                                                                                                                                                                                                                                            1337
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                29
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                    29
                                                                                                                                                                                                                                                           219
                                                                                                                                                                                                                                                                                            1337
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                 39
                                                                                                                                                                                                                                                           217
                                                                                                                                                                                                                                                                                            2032
                                                                                                                                                                                                                                                                                                                                                                                                                                0 ...
                                                                         142477
                                                                                                                                                                                                                                                                  0
                                                                                                                                                                                                                                                                                            5636
                                                                                                                                                                                                                                                                                                                                                                                                                0 0 ...
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                   1
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                    41
                                                                         148154
                                                                                                                         61
                                                                                                                                                                                                                                                            294
                                                                                                                                                                                                                                                                                                                                                                                                                              0 ...
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             255
                                                                                                                                                                                                                                                                                            3929
                                                                                                                                                                                                       17 0
                                                                                                                                                                                                                                                              32
                                                                         397011
                                                                         452001
                                                                                                                                                                                                                                                                  4
                                                                                                                                                                                                                                                                                                                                                                                                                                0 ...
                                                                                                                             0
                                                                                                                                                                                                       17
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                       1
                                                                         452002
                                                                                                                                                                                                       17 0
                                                                                                                                                                                                                                                                                                                                                                                                                0 0 ...
```

2379 rows × 41 columns

♦ K-means Algorithm with KDD-99 Dataset

- Step 6. Scaling data

♦ K-means Algorithm with KDD-99 Dataset

- Step 7. Dimensionality reduction (41 => 3)

♦ K-means Algorithm with KDD-99 Dataset

- Step 8. Color generation (for color map generation)

```
In [15] : colors = [plt.cm.Spectral(e) for e in np.linspace(0, 1, len(unique labels))]
In [16]:
            colors
Out [16]: [(0.6196078431372549, 0.00392156862745098, 0.25882352941176473, 1.0),
             (0.7126489811610919, 0.10711264898116109, 0.28081507112648985, 1.0),
             (0.8141484044598232, 0.2196847366397539, 0.3048058439061899, 1.0),
             (0.8758169934640523, 0.3045751633986928, 0.29411764705882354, 1.0),
             (0.9330257593233372, 0.3913110342176086, 0.27197231833910035, 1.0),
             (0.9665513264129182, 0.49742406766628217, 0.295040369088812, 1.0),
             (0.9817762399077278, 0.6073817762399076, 0.3457900807381776, 1.0),
             (0.9928489042675894, 0.716955017301038, 0.40945790080738165, 1.0),
             (0.9946943483275663, 0.8092272202998846, 0.48696655132641287, 1.0),
             (0.9963860053825452, 0.8879661668589004, 0.5610918877354863, 1.0),
             (0.9982314494425221, 0.9451749327181853, 0.6570549788542868, 1.0),
             (0.998077662437524, 0.9992310649750096, 0.7460207612456747, 1.0),
             (0.9557862360630527, 0.9823144944252211, 0.6800461361014996, 1.0),
             (0.9096501345636295, 0.9638600538254518, 0.6080738177623992, 1.0),
             (0.8202998846597465, 0.9275663206459055, 0.6126874279123413, 1.0),
             (0.7114186851211075, 0.8832756632064592, 0.6348327566320646, 1.0),
             (0.5910034602076126, 0.835524798154556, 0.6442906574394464, 1.0),
```


♦ K-means Algorithm with KDD-99 Dataset

- Step 9. Generate ground-truth color map

```
In [17] : def gen color dict( unique labels, colors):
              color dict = dict()
              for i in range(len( unique labels)):
                  color dict[ unique labels[i]] = colors[i]
              return color dict
In [18] : gt color dict = gen color dict(unique labels, colors)
In [19]:
           gt color dict
Out [19]: {'normal.': (0.6196078431372549, 0.00392156862745098, 0.25882352941176473, 1.0),
             'buffer overflow.': (0.7126489811610919, 0.10711264898116109, 0.28081507112648985,
            1.0),
             'loadmodule.': (0.8141484044598232, 0.2196847366397539, 0.3048058439061899, 1.0),
             'perl.': (0.8758169934640523, 0.3045751633986928, 0.29411764705882354, 1.0),
             'neptune.': (0.9330257593233372, 0.3913110342176086, 0.27197231833910035, 1.0),
             'smurf.': (0.9665513264129182, 0.49742406766628217, 0.295040369088812, 1.0),
             'guess passwd.': (0.9817762399077278, 0.6073817762399076, 0.3457900807381776, 1.0)
             'pod.': (0.9928489042675894, 0.716955017301038, 0.40945790080738165, 1.0),
```

♦ K-means Algorithm with KDD-99 Dataset

- Step 10. Plot ground-truth cluster image




♦ K-means Algorithm with KDD-99 Dataset

- Step 11. Apply k-means algorithm and generate k-means cluster color map

♦ K-means Algorithm with KDD-99 Dataset

- Step 12. Plot k-means cluster image



♦ K-means Algorithm with KDD-99 Dataset

- Step 13. Check metrics

```
In [24] : print("Homogeneity: %0.3f" % metrics.homogeneity_score(labels, kmeans_label))
    print("Completeness: %0.3f" % metrics.completeness_score(labels, kmeans_label))
    print("V-measure: %0.3f" % metrics.v_measure_score(labels, kmeans_label))
```

Out [24] : Homogeneity: 0.775

Completeness: 0.716 V-measure: 0.744

Homogeneity : 각 cluster들이 각 class의 data points만을 포함함

Completeness: 각 class의 모든 data points가 동일한 cluster 내에 있음

V-measure : Homogeneity와 completeness의 조화 평균


♦ DBSCAN Algorithm

- Density 기반의 clustering 알고리즘
- 알고리즘을 설명하기위해 다음 5가지 용어를 정의함

Core Eps

Noise MinPts

Border



♦ DBSCAN Algorithm

- Algorithm


Setp1. 임의의 오브젝트 P를 선택

Setp2. Eps와 MinPts를 만족하는 P와 연결된 모든 포인트를 탐색

Setp3-1. 만약 P가 Core 라면 새로운 클러스터를 생성

Setp3-2. 만약 P가 Border 또는 Noise 라면, 데이터베이스 내의 다른 오브젝트를 P로 선택

Setp4. 모든 오브젝트를 방문할 때까지 반복



◆ DBSCAN Algorithm with KDD-99 Dataset

- Step 1. Import all package

```
In [1]: import csv
    import numpy as np
    import pandas as pd
    import matplotlib.pyplot as plt

from sklearn import metrics
    from sklearn.cluster import KMeans
    from sklearn.cluster import DBSCAN
    from sklearn.decomposition import PCA
    from sklearn.preprocessing import MinMaxScaler
```

- Step 2. Load KDD-99 Dataset

◆ DBSCAN Algorithm with KDD-99 Dataset

```
In [3] : with open('./kddcup.data_10_percent_corrected', 'r') as file:
             data = pd.read csv(file, names=col names)
In [4]: data['label'].value counts()
Out [4]: smurf. 280790
          neptune. 107201
          normal, 97278
          back. 2203
          satan. 1589
          ipsweep. 1247
          portsweep. 1040
          warezclient. 1020
          teardrop. 979
          pod. 264
          nmap. 231
          guess_passwd. 53
          buffer_overflow. 30
          land. 21
          warezmaster. 20
          Name: label, dtype: int64
```

◆ DBSCAN Algorithm with KDD-99 Dataset

- Step 3. Extract data by several per label

```
In [5]:
           unique_labels = data['label'].unique()
            unique labels
Out [5]: array(['normal.', 'buffer overflow.', 'loadmodule.', 'perl.', 'neptune.', 'smurf.',
                    'guess_passwd.', 'pod.', 'teardrop.', 'portsweep.', 'ipsweep.', 'land.',
                    'ftp_write.', 'back.', 'imap.', 'satan.', 'phf.', 'nmap.', 'multihop.',
                    'warezmaster.', 'warezclient.', 'spy.', 'rootkit.'], dtype=object)
In [6] : selected data = pd.DataFrame()
            for label in unique labels:
                 selected data = pd.concat([selected data, data.loc[data['label'] == label][:200]])
            selected data
Out [6]:
                   duration protocol_type service flag src_bytes dst_bytes land wrong_fragment urgent hot ... dst_host_srv_count dst_host_same_srv_rate dst_l
                                                                           0 0 ...
                                                                                             9
                0
                       0
                                    http
                                        SF
                                               181
                                                     5450
                                                                                                           1.00
                                                                              0 ...
                               tcp
                                    http
                                        SF
                                               239
                                                      486
                                                           0
                                                                                             19
                                                                                                           1.00
                                                                           0 0 ...
                                    http SF
                                               235
                                                     1337
                                                                                                           1.00
                       0
                                       SF
                                                                           0 0 ...
                                                                                             39
                                                                                                           1.00
                                    http
                                               219
                                                     1337
                               tcp
                                    http SF
                                               217
                                                     2032
                                                                           0 0 ...
                                                                                             49
                                                                                                           1.00
                               tcp
```

◆ DBSCAN Algorithm with KDD-99 Dataset

- Step 4. Separate data and label

```
In [8] : labels = selected_data['label'].to_numpy()
labels
Out [8] : array(['normal.', 'normal.', '..., 'rootkit.', 'rootkit.'], dtype=object)
In [9] : data = selected_data.drop('label', axis=1)
data
```

Out [9]:

	duration	protocol_type	service	flag	src_bytes	dst_bytes	land	wrong_fragment	urgent	hot	 dst_host_count	dst_host_srv_count	dst_host_san
0	0	tcp	http	SF	181	5450	0	0	0	0	 9	9	
1	0	tcp	http	SF	239	486	0	0	0	0	 19	19	
2	0	tcp	http	SF	235	1337	0	0	0	0	 29	29	
3	0	tcp	http	SF	219	1337	0	0	0	0	 39	39	
4	0	tcp	http	SF	217	2032	0	0	0	0	 49	49	
142477	0	tcp	ftp_data	SF	0	5636	0	0	0	0	 1	41	
148154	61	tcp	telnet	SF	294	3929	0	0	0	0	 255	4	
397011	0	udp	other	SF	32	0	0	0	0	0	 255	1	

♦ DBSCAN Algorithm with KDD-99 Dataset

- Step 5. Convert nominal data to numeric data

```
In [10]:
                data['protocol_type'], _ = data['protocol_type'].factorize()
                data['service'], _ = data['service'].factorize()
                data['flag'], _ = data['flag'].factorize()
                data
Out [10]:
                      duration protocol_type service flag src_bytes dst_bytes land wrong_fragment urgent hot ... dst_host_count dst_host_srv_count dst_host_same
                    0
                           0
                                                       181
                                                                    0
                                                                                 0
                                                                                       0 0 ...
                                                                                                         9
                                                                                                                        9
                                            0
                                                              5450
                    1
                           0
                                                      239
                                                                    0
                                                                                       0 0 ...
                                                                                                         19
                                                                                                                       19
                                                              486
                                                      235
                                                                                          0 ...
                                                                                                                       29
                                                              1337
                                                                                                         29
                                                      219
                                                              1337
                                                                                                         39
                           0
                                                      217
                                                              2032
                                                                                           0 ...
                                                                                                         49
                142477
                           0
                                                        0
                                                              5636
                                                                                 0
                                                                                       0 0 ...
                                                                                                         1
                                                                                                                       41
                148154
                          61
                                                       294
                                                                                          0 ...
                                                                                                        255
                                                              3929
                                           17 0
                                                       32
                397011
                452001
                           0
                                           17
                                                        4
                                                                                           0 ...
                                                                                                                        1
                452002
                                           17 0
                                                                                       0 0 ...
```

2379 rows × 41 columns

◆ DBSCAN Algorithm with KDD-99 Dataset

- Step 6. Scaling data

◆ DBSCAN Algorithm with KDD-99 Dataset

- Step 7. Dimensionality reduction (41 => 3)

◆ DBSCAN Algorithm with KDD-99 Dataset

- Step 8. Color generation (for color map generation)

```
In [15] : colors = [plt.cm.Spectral(e) for e in np.linspace(0, 1, len(unique labels))]
In [16]:
            colors
Out [16]: [(0.6196078431372549, 0.00392156862745098, 0.25882352941176473, 1.0),
             (0.7126489811610919, 0.10711264898116109, 0.28081507112648985, 1.0),
             (0.8141484044598232, 0.2196847366397539, 0.3048058439061899, 1.0),
             (0.8758169934640523, 0.3045751633986928, 0.29411764705882354, 1.0),
             (0.9330257593233372, 0.3913110342176086, 0.27197231833910035, 1.0),
             (0.9665513264129182, 0.49742406766628217, 0.295040369088812, 1.0),
             (0.9817762399077278, 0.6073817762399076, 0.3457900807381776, 1.0),
             (0.9928489042675894, 0.716955017301038, 0.40945790080738165, 1.0),
             (0.9946943483275663, 0.8092272202998846, 0.48696655132641287, 1.0),
             (0.9963860053825452, 0.8879661668589004, 0.5610918877354863, 1.0),
             (0.9982314494425221, 0.9451749327181853, 0.6570549788542868, 1.0),
             (0.998077662437524, 0.9992310649750096, 0.7460207612456747, 1.0),
             (0.9557862360630527, 0.9823144944252211, 0.6800461361014996, 1.0),
             (0.9096501345636295, 0.9638600538254518, 0.6080738177623992, 1.0),
             (0.8202998846597465, 0.9275663206459055, 0.6126874279123413, 1.0),
             (0.7114186851211075, 0.8832756632064592, 0.6348327566320646, 1.0),
             (0.5910034602076126, 0.835524798154556, 0.6442906574394464, 1.0),
```

♦ DBSCAN Algorithm with KDD-99 Dataset

- Step 9. Generate ground-truth color map

```
In [17] : def gen color dict( unique labels, colors):
              color dict = dict()
              for i in range(len( unique labels)):
                  color dict[ unique labels[i]] = colors[i]
              return color dict
In [18] : gt color dict = gen color dict(unique labels, colors)
In [19]:
           gt color dict
Out [19]: {'normal.': (0.6196078431372549, 0.00392156862745098, 0.25882352941176473, 1.0),
             'buffer overflow.': (0.7126489811610919, 0.10711264898116109, 0.28081507112648985,
            1.0),
             'loadmodule.': (0.8141484044598232, 0.2196847366397539, 0.3048058439061899, 1.0),
             'perl.': (0.8758169934640523, 0.3045751633986928, 0.29411764705882354, 1.0),
             'neptune.': (0.9330257593233372, 0.3913110342176086, 0.27197231833910035, 1.0),
             'smurf.': (0.9665513264129182, 0.49742406766628217, 0.295040369088812, 1.0),
             'guess passwd.': (0.9817762399077278, 0.6073817762399076, 0.3457900807381776, 1.0)
             'pod.': (0.9928489042675894, 0.716955017301038, 0.40945790080738165, 1.0),
```

◆ DBSCAN Algorithm with KDD-99 Dataset

- Step 10. Color generation (for color map generation)

```
In [24] : colors = [plt.cm.Spectral(e) for e in np.linspace(0, 1, len(unique labels))]
In [25]:
            colors
Out [25]: [(0.6196078431372549, 0.00392156862745098, 0.25882352941176473, 1.0),
             (0.7126489811610919, 0.10711264898116109, 0.28081507112648985, 1.0),
             (0.8141484044598232, 0.2196847366397539, 0.3048058439061899, 1.0),
             (0.8758169934640523, 0.3045751633986928, 0.29411764705882354, 1.0),
             (0.9330257593233372, 0.3913110342176086, 0.27197231833910035, 1.0),
             (0.9665513264129182, 0.49742406766628217, 0.295040369088812, 1.0),
             (0.9817762399077278, 0.6073817762399076, 0.3457900807381776, 1.0),
             (0.9928489042675894, 0.716955017301038, 0.40945790080738165, 1.0),
             (0.9946943483275663, 0.8092272202998846, 0.48696655132641287, 1.0),
             (0.9963860053825452, 0.8879661668589004, 0.5610918877354863, 1.0),
             (0.9982314494425221, 0.9451749327181853, 0.6570549788542868, 1.0),
             (0.998077662437524, 0.9992310649750096, 0.7460207612456747, 1.0),
             (0.9557862360630527, 0.9823144944252211, 0.6800461361014996, 1.0),
             (0.9096501345636295, 0.9638600538254518, 0.6080738177623992, 1.0),
             (0.8202998846597465, 0.9275663206459055, 0.6126874279123413, 1.0),
             (0.7114186851211075, 0.8832756632064592, 0.6348327566320646, 1.0),
             (0.5910034602076126, 0.835524798154556, 0.6442906574394464, 1.0),
```


♦ DBSCAN Algorithm with KDD-99 Dataset

- Step 9. Generate ground-truth color map

```
In [17] : def gen color dict( unique labels, colors):
              color dict = dict()
              for i in range(len( unique labels)):
                  color dict[ unique labels[i]] = colors[i]
              return color dict
In [18] : gt color dict = gen color dict(unique labels, colors)
In [19]:
           gt color dict
Out [19]: {'normal.': (0.6196078431372549, 0.00392156862745098, 0.25882352941176473, 1.0),
             'buffer overflow.': (0.7126489811610919, 0.10711264898116109, 0.28081507112648985,
            1.0),
             'loadmodule.': (0.8141484044598232, 0.2196847366397539, 0.3048058439061899, 1.0),
             'perl.': (0.8758169934640523, 0.3045751633986928, 0.29411764705882354, 1.0),
             'neptune.': (0.9330257593233372, 0.3913110342176086, 0.27197231833910035, 1.0),
             'smurf.': (0.9665513264129182, 0.49742406766628217, 0.295040369088812, 1.0),
             'guess passwd.': (0.9817762399077278, 0.6073817762399076, 0.3457900807381776, 1.0)
             'pod.': (0.9928489042675894, 0.716955017301038, 0.40945790080738165, 1.0),
```

◆ DBSCAN Algorithm with KDD-99 Dataset

- Step 10. Plot ground-truth cluster image



◆ DBSCAN Algorithm with KDD-99 Dataset

- Step 13. Apply DBSCAN algorithm and generate k-means cluster color map

◆ DBSCAN Algorithm with KDD-99 Dataset

- Step 14. Plot DBSCAN cluster image

```
In [32] : fig = plt.figure()
            ax = fig.add_subplot(111, projection='3d')
            for i in range(len(data)):
                ax.scatter(data[i][0], data[i][1], data[i][2],
            c=[dbscan_color_dict[dbscan_label[i]]])
            plt.show()
Out [32]:
                                 1.0
                                 0.5
                                 -0.5
                                 -1.0
```

◆ DBSCAN Algorithm with KDD-99 Dataset

- Step 15. Check metrics

Homogeneity : 각 cluster들이 각 class의 data points만을 포함함

Completeness: 각 class의 모든 data points가 동일한 cluster 내에 있음

V-measure : Homogeneity와 completeness의 조화 평균

